

TA1 Actividades de fundamentos

Índice

1. Introducción
2. Análisis de componentes principales (PCA)
3. Gradiente
4. Jacobiana
5. Descenso por gradiente
6. Cálculo matricial
7. Optimización con restricciones
8. Distribución de Bernoulli
9. Distribución categórica
10. Distribución Gaussiana
11. Entropía
12. Estimación máximo-verosímil (MLE)
13. Minimización del riesgo empírico (ERM)
14. Regularización
15. Decisión

1 Introducción

☐ Indica la respuesta incorrecta o la última opción si las tres primeras son correctas.

1. En ML (probabilístico), las tareas de clasificación suelen plantearse con modelos de la forma $p(y \mid \mathbf{x}; \boldsymbol{\theta})$, entrada $\mathbf{x} \in \mathbb{R}^D$, salida $y \in \{1, \dots, C\}$ y parámetros $\boldsymbol{\theta}$.
2. En ML (probabilístico), las tareas de regresión suelen plantearse con modelos de la forma $p(y \mid \mathbf{x}; \boldsymbol{\theta})$, entrada $\mathbf{x} \in \mathbb{R}^D$, salida $y \in \mathbb{R}$ y parámetros $\boldsymbol{\theta}$.
3. En aprendizaje supervisado se asume que disponemos de un conjunto de datos supervisados o etiquetados, $\mathcal{D} = \{(\mathbf{x}_n, y_n)\}_{n=1}^N$.
4. Las tres opciones anteriores son correctas.

Solución: La 4.

2 Análisis de componentes principales (PCA)

□ Sea $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ un conjunto de N datos D dimensionales que queremos reducir a K dimensiones, $K \ll D$, mediante PCA; esto es, hallando una proyección lineal ortogonal $\mathbf{W} \in \mathbb{R}^{D \times K}$ que minimice el error de reconstrucción. Este objetivo puede expresarse formalmente como:

1. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{decode}(\text{encode}(\mathbf{x}_n))\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W}^t \mathbf{x}$ y $\text{decode}(\mathbf{z}) = \mathbf{W} \mathbf{z}$
2. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{decode}(\text{encode}(\mathbf{x}_n))\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W} \mathbf{x}$ y $\text{decode}(\mathbf{z}) = \mathbf{W}^t \mathbf{z}$
3. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{encode}(\text{decode}(\mathbf{x}_n))\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W}^t \mathbf{x}$ y $\text{decode}(\mathbf{z}) = \mathbf{W} \mathbf{z}$
4. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{encode}(\text{decode}(\mathbf{x}_n))\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W} \mathbf{x}$ y $\text{decode}(\mathbf{z}) = \mathbf{W}^t \mathbf{z}$

Solución: La 1.

□ Sea $\mathcal{D} = \{\mathbf{x}_1, \dots, \mathbf{x}_N\}$ un conjunto de N datos D dimensionales que queremos reducir a K dimensiones, $K \ll D$, mediante PCA; esto es, hallando una proyección lineal ortogonal $\mathbf{W} \in \mathbb{R}^{D \times K}$ que minimice el error de reconstrucción. Este objetivo puede expresarse formalmente como:

1. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{encode}(\mathbf{x}_n)\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W}^t \mathbf{x}$
2. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{encode}(\mathbf{x}_n)\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W} \mathbf{x}$
3. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{decode}(\text{encode}(\mathbf{x}_n))\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W}^t \mathbf{x}$ y $\text{decode}(\mathbf{z}) = \mathbf{W} \mathbf{z}$
4. $\mathcal{L}(\mathbf{W}) = \frac{1}{N} \sum_n \|\mathbf{x}_n - \text{decode}(\text{encode}(\mathbf{x}_n))\|_2^2$ con $\text{encode}(\mathbf{x}) = \mathbf{W} \mathbf{x}$ y $\text{decode}(\mathbf{z}) = \mathbf{W}^t \mathbf{z}$

Solución: La 3.

Problema: Sea $\mathcal{D} = \{\mathbf{x}_1 = (-1, -1)^t, \mathbf{x}_2 = (1, 3)^t, \mathbf{x}_3 = (3, 1)^t, \mathbf{x}_4 = (3, 3)^t\}$ un conjunto de $N = 4$ datos de $D = 2$ dimensiones que queremos reducir a $K = 1$ dimensión. Codifica, decodifica y halla la distorsión de los datos con $\mathbf{W} = (\sqrt{2}/2, \sqrt{2}/2)^t$.

Solución:

$$\begin{array}{llll} \mathbf{x}_1 = (-1, -1)^t & \mathbf{x}_2 = (1, 3)^t & \mathbf{x}_3 = (3, 1)^t & \mathbf{x}_4 = (3, 3)^t \\ z_1 = \mathbf{W}^t \mathbf{x}_1 = -\sqrt{2} & z_2 = 2\sqrt{2} & z_3 = 2\sqrt{2} & z_4 = 3\sqrt{2} \\ \hat{\mathbf{x}}_1 = \mathbf{W} z_1 = (-1, -1)^t & \hat{\mathbf{x}}_2 = (2, 2)^t & \hat{\mathbf{x}}_3 = (2, 2)^t & \hat{\mathbf{x}}_4 = (3, 3)^t \end{array}$$

$$\mathcal{L}(\mathbf{W}) = \frac{1}{4} (\|\mathbf{x}_1 - \hat{\mathbf{x}}_1\|_2^2 + \|\mathbf{x}_2 - \hat{\mathbf{x}}_2\|_2^2 + \|\mathbf{x}_3 - \hat{\mathbf{x}}_3\|_2^2 + \|\mathbf{x}_4 - \hat{\mathbf{x}}_4\|_2^2) = \frac{1}{4} (0 + 2 + 2 + 0) = 1$$

Problema: Sea $\mathcal{D} = \{\mathbf{x}_1 = (-1, -1)^t, \mathbf{x}_2 = (1, 3)^t, \mathbf{x}_3 = (3, 1)^t, \mathbf{x}_4 = (3, 3)^t\}$ un conjunto de datos de $D = 2$ dimensiones que queremos reducir a $K = 1$ dimensión. Halla la proyección $\mathbf{W} \in \mathbb{R}^{D \times K}$ que escoge PCA.

Solución:

$$\boldsymbol{\mu} = \begin{pmatrix} 3/2 \\ 3/2 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} 11/4 & 7/4 \\ 7/4 & 11/4 \end{pmatrix}$$

$$\boldsymbol{\Sigma} = \mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^t \quad \text{con} \quad \mathbf{U} = \begin{pmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix} \quad \text{y} \quad \boldsymbol{\Lambda} = \begin{pmatrix} \frac{9}{2} & 0 \\ 0 & 1 \end{pmatrix} \quad \rightarrow \quad \mathbf{W} = \begin{pmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{pmatrix}$$

☐ Sea $\mathbf{X}$ una matriz de N datos centrados de $D = 2$ dimensiones que queremos reducir a una dimensión. De la SVD de $\mathbf{X}$, $\mathbf{X} = \mathbf{U}\mathbf{S}\mathbf{V}^t$, se sabe que:

$$\mathbf{S} = \text{diag}(\sqrt{18}, 2) \quad \text{y} \quad \mathbf{V}^t = \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \end{pmatrix}$$

Determina la proyección lineal $\mathbf{W}$ que escoge PCA para codificar los datos con $\text{encode}(\mathbf{x}) = \mathbf{W}^t \mathbf{x}$.

1. $\mathbf{W}^t = (\sqrt{2}/2, \sqrt{2}/2)$
2. $\mathbf{W}^t = (3, 3)$
3. $\mathbf{W}^t = (\sqrt{2}/2, -\sqrt{2}/2)$
4. $\mathbf{W}^t = (\sqrt{2}, -\sqrt{2})$

Solución: La 1; la primera fila de $\mathbf{V}^t$, correspondiente al mayor valor singular.

3 Gradiente

□ Sea $\mathcal{L} : \mathbb{R}^D \rightarrow \mathbb{R}$ una función objetivo doblemente diferenciable, con gradiente $\mathbf{g}(\boldsymbol{\theta}) = \nabla \mathcal{L}(\boldsymbol{\theta})$ y Hessiana $\mathbf{H}(\boldsymbol{\theta}) = \nabla^2 \mathcal{L}(\boldsymbol{\theta})$. Sean $\mathbf{g}^* = \mathbf{g}(\boldsymbol{\theta})|_{\boldsymbol{\theta}^*}$ y $\mathbf{H}^* = \mathbf{H}(\boldsymbol{\theta})|_{\boldsymbol{\theta}^*}$, respectivamente, el gradiente y Hessiana de $\mathcal{L}$ en $\boldsymbol{\theta}^* \in \mathbb{R}^D$. En relación con las condiciones de optimalidad local del objetivo en $\boldsymbol{\theta}^*$, indica la respuesta incorrecta o la última opción si las tres primeras son correctas.

1. $\mathbf{g}^* = \mathbf{0}$ es condición necesaria para que $\boldsymbol{\theta}^*$ sea mínimo local
2. $\mathbf{H}^* \succeq 0$ (semidefinida positiva) es condición suficiente para que $\boldsymbol{\theta}^*$ sea mínimo local
3. Si $\mathbf{g}^* = \mathbf{0}$ y $\mathbf{H}^*$ es indefinida, $\boldsymbol{\theta}^*$ es mínimo o máximo local
4. Las tres opciones anteriores son correctas


Solución: La 3; puede ser un punto de silla ($D = 2$).

□ Sean la función $f(\mathbf{x}) = a_1 x_1^4 + a_2 x_2^4$ con $a_1, a_2 < 0$, $\mathbf{x}$ un punto estacionario de f , y $\mathbf{H}(\mathbf{x})$ la Hessiana de f evaluada en $\mathbf{x}$. Indica la respuesta correcta:

1. $\mathbf{H}(\mathbf{x}) = \text{diag}(4a_1 x_1^3, 4a_2 x_2^3)$ y $\mathbf{x}$ es mínimo (local) de f
2. $\mathbf{H}(\mathbf{x}) = \text{diag}(4a_1 x_1^3, 4a_2 x_2^3)$ y $\mathbf{x}$ es máximo (local) de f
3. $\mathbf{H}(\mathbf{x}) = \text{diag}(12a_1 x_1^2, 12a_2 x_2^2)$ y $\mathbf{x}$ es mínimo (local) de f
4. $\mathbf{H}(\mathbf{x}) = \text{diag}(12a_1 x_1^2, 12a_2 x_2^2)$ y $\mathbf{x}$ es máximo (local) de f

Solución: La 4.

```
In [ ]: import numpy as np; import matplotlib.pyplot as plt
R = np.linspace(-1, 1, 50); X1, X2 = np.meshgrid(R, R); X = np.c_[np.ravel(X1), np.ravel(X2)]
a = np.array([-1, -1]); Y = (np.power(X, 4) @ a).reshape(X1.shape)
fig = plt.figure(figsize=(6, 2)); ax = plt.subplot(121)
cp = ax.contourf(X1, X2, Y, 15, cmap='Blues_r'); plt.colorbar(cp, ax=ax, shrink=.8)
r = np.linspace(-1, 1, 15); x1, x2 = np.meshgrid(r, r); x = np.c_[np.ravel(x1), np.ravel(x2)]
neg_grad = -np.power(x, 3) @ np.diag(4 * a)
ax.quiver(x[:, 0], x[:, 1], neg_grad[:, 0], neg_grad[:, 1], color='C1');
ax = plt.subplot(122, projection='3d'); ax.set_xlabel('$x_1$'); ax.set_ylabel('$x_2$')
ax.set_title(rf'$y=\{a[0]:.1f\}x_1^4 + \{a[1]:.1f\}x_2^4$'); ax.text(0, 0, 0, '**')
ax.plot_wireframe(x1, x2, a[0]*x1**4 + a[1]*x2**4);
```



4 Jacobiana

☐ Indica la respuesta incorrecta o la última opción si las tres primeras son correctas.

1. La Jacobiana de una función de $\mathbb{R}^n$ en $\mathbb{R}$ es su gradiente transpuesto.
2. La Jacobiana del gradiente de una función de $\mathbb{R}^n$ en $\mathbb{R}$ es su Hessiana.
3. La Jacobiana de $\mathbf{y} = \mathbf{W}\mathbf{x}$, $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{W} \in \mathbb{R}^{m \times n}$, respecto a $\mathbf{x}$, es $\mathbf{W}$.
4. Las tres opciones anteriores son correctas.

Solución: La 4.

5 Descenso por gradiente

Problema: Dada la función objetivo $\mathcal{L}(\theta) = \theta^4$, aplica dos iteraciones de descenso por gradiente a partir de $\theta_0 = 1$, con factor de aprendizaje $\eta = 0.1$

Solución:

$$\begin{aligned}\frac{d\mathcal{L}(\theta)}{d\theta} &= 4\theta^3 \\ \theta_1 &= \theta_0 - 0.1 \cdot 4 \cdot \theta_0^3 = 1 - 0.4 \cdot 1^3 = 0.6 \\ \theta_2 &= \theta_1 - 0.1 \cdot 4 \cdot \theta_1^3 = 0.6 - 0.4 \cdot (0.6)^3 = 0.5136\end{aligned}$$

```
In [ ]: import numpy as np
def GDld(g, x0, eta=0.1, tol=1e-3, max_iter=2):
    x = x0; delta = np.inf; i = 0
    while np.max(np.abs(delta)) > tol and i < max_iter:
        x = x - eta * g(x); i = i + 1
        print(f'x = {x:.4f} f = {f(x):.4f}')
```

```
In [ ]: f = lambda t: np.power(t, 4); g = lambda t: 4 * np.power(t, 3); GDld(g, 1)

x = 0.6000 f = 0.1296
x = 0.5136 f = 0.0696
```

Problema: Dada la función objetivo $\mathcal{L}(\theta) = \theta^4$, aplica dos iteraciones de descenso por gradiente con momentum a partir de $\theta_0 = 1$, con factor de aprendizaje $\eta = 0.1$ y $\beta = 0.9$

Solución:

$$\begin{aligned}\frac{d\mathcal{L}(\theta)}{d\theta} &= 4 \cdot \theta^3 \\ m_1 &= \beta m_0 + g(\theta_0) = 0.9 \cdot 0 + 4 \cdot \theta_0^3 = 4 \\ \theta_1 &= \theta_0 - \eta m_1 = 1 - 0.1 \cdot 4 = 0.6 \\ m_2 &= \beta m_1 + g(\theta_1) = 0.9 \cdot 4 + 4 \cdot \theta_1^3 = 4.4640 \\ \theta_2 &= \theta_1 - \eta m_2 = 0.6 - 0.1 \cdot 4.4640 = 0.1536\end{aligned}$$

```
In [ ]: import numpy as np
def GDld_momentum(g, x0, eta=0.1, beta=0.9, tol=1e-3, max_iter=2):
    x = x0; delta = np.inf; i = 0; m = np.zeros_like(x)
    while np.max(np.abs(delta)) > tol and i < max_iter:
        m = beta * m + g(x); x = x - eta * m; i = i + 1
        print(f'm = {m:.4f} x = {x:.4f} f = {f(x):.4f}')
```

```
In [ ]: f = lambda t: np.power(t, 4); g = lambda t: 4 * np.power(t, 3); GDld_momentum(g, 1)

m = 4.0000 x = 0.6000 f = 0.1296
m = 4.4640 x = 0.1536 f = 0.0006
```

Problema: Dada la función objetivo $\mathcal{L}(\theta) = \theta^4$, aplica dos iteraciones de descenso por gradiente con momentum Nesterov a partir de $\theta_0 = 1$, con factor de aprendizaje $\eta = 0.1$ y $\beta = 0.9$

Solución:

$$\frac{d\mathcal{L}(\theta)}{d\theta} = 4 \cdot \theta^3$$

$$m_1 = \beta m_0 - \eta g(\theta_0 + \beta m_0) = 0 - 0.1 \cdot 4 \cdot 1^3 = -0.4$$

$$\theta_1 = \theta_0 + m_0 = 1 - 0.4 = 0.6$$

$$m_2 = \beta m_1 - \eta g(\theta_1 + \beta m_1) = 0.9 \cdot (-0.4) - 0.1 \cdot 4 \cdot (0.6 + 0.9 \cdot (-0.4))^3 = -0.3655$$

$$\theta_2 = \theta_1 + m_1 = 0.6 - 0.3655 = 0.2345$$

```
In [ ]: import numpy as np
def GDld_momentum(g, x0, eta=0.1, beta=0.9, tol=1e-3, max_iter=2):
    x = x0; delta = np.inf; i = 0; m = np.zeros_like(x)
    while np.max(np.abs(delta)) > tol and i < max_iter:
        m = beta * m - eta * g(x + beta * m); x = x + m; i = i + 1
    print(f'm = {m:.4f} x = {x:.4f} f = {f(x):.4f}')
```

```
In [ ]: f = lambda t: np.power(t, 4); g = lambda t: 4 * np.power(t, 3); GDld_momentum(g, 1)

m = -0.4000 x = 0.6000 f = 0.1296
m = -0.3655 x = 0.2345 f = 0.0030
```


6 Cálculo matricial

□ El cálculo matricial es una notación especializada para manejar derivadas parciales con matrices. Sean $\mathbf{x} \in \mathbb{R}^3$ e $\mathbf{y} = \mathbf{f}(\mathbf{x}) \in \mathbb{R}^2$. De acuerdo con el formato numerador (que seguimos en la asignatura), la Jacobiana de $\mathbf{y}$ respecto de $\mathbf{x}$ es:

1. $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \frac{\partial y_1}{\partial x_3} & \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} & \frac{\partial y_2}{\partial x_3} \end{bmatrix}$

2. $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \frac{\partial y_1}{\partial x_3} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} & \frac{\partial y_2}{\partial x_3} \end{bmatrix}$

3. $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_2}{\partial x_1} \\ \frac{\partial y_1}{\partial x_2} & \frac{\partial y_2}{\partial x_2} \\ \frac{\partial y_1}{\partial x_3} & \frac{\partial y_2}{\partial x_3} \end{bmatrix}$

4. Ninguna de las anteriores

Solución: La 2.

Problema: Sean $y = \mathbf{u}^t \mathbf{W} \mathbf{x}$, $\mathbf{u} \in \mathbb{R}^m$, $\mathbf{W} \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$, $m = 2$, $n = 3$. Prueba que $\frac{\partial y}{\partial \mathbf{W}} = \mathbf{x} \mathbf{u}^t$

Solución:

$$\begin{aligned} y &= (u_1, u_2) \begin{pmatrix} W_{11} & W_{12} & W_{13} \\ W_{21} & W_{22} & W_{23} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \\ &= (u_1 W_{11} + u_2 W_{21}, u_1 W_{12} + u_2 W_{22}, u_1 W_{13} + u_2 W_{23}) \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} \\ &= u_1 W_{11} x_1 + u_2 W_{21} x_1 + u_1 W_{12} x_2 + u_2 W_{22} x_2 + u_1 W_{13} x_3 + u_2 W_{23} x_3 \\ \frac{\partial y}{\partial \mathbf{W}} &= \begin{pmatrix} \frac{\partial y}{\partial W_{11}} & \frac{\partial y}{\partial W_{21}} \\ \frac{\partial y}{\partial W_{12}} & \frac{\partial y}{\partial W_{22}} \\ \frac{\partial y}{\partial W_{13}} & \frac{\partial y}{\partial W_{23}} \end{pmatrix} = \begin{pmatrix} u_1 x_1 & u_2 x_1 \\ u_1 x_2 & u_2 x_2 \\ u_1 x_3 & u_2 x_3 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} (u_1, u_2) = \mathbf{x} \mathbf{u}^t \end{aligned}$$

El desarrollo es válido para todo $m, n \geq 1$.

Problema: Sean $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{y} = \boldsymbol{\varphi}(\mathbf{x}) \in \mathbb{R}^n$, $y_i = \varphi(x_i)$, $i = 1, \dots, n$, con $\varphi(z) = \text{ReLU}(z) = \max(z, 0)$, $\varphi'(z) = \text{ReLU}'(z) = \mathbb{I}(z > 0)$. Prueba que

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \text{diag}(\mathbb{I}(x_1 > 0), \dots, \mathbb{I}(x_n > 0))$$

Solución:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} \varphi(x_1) \\ \varphi(x_2) \\ \vdots \\ \varphi(x_n) \end{bmatrix} \quad \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_n}{\partial x_1} & \dots & \frac{\partial y_n}{\partial x_n} \end{bmatrix} = \text{diag}(\mathbb{I}(x_1 > 0), \dots, \mathbb{I}(x_n > 0))$$

Problema: Sean $y = \mathbf{u}^t \boldsymbol{\varphi}(\mathbf{h})$, $\mathbf{h} = \mathbf{W}\mathbf{x}$, $\mathbf{u} \in \mathbb{R}^m$, $\mathbf{h} \in \mathbb{R}^m$, $\boldsymbol{\varphi} : \mathbb{R}^m \rightarrow \mathbb{R}^m$ tal que $\varphi_i = \varphi(x_i)$, $i = 1, \dots, m$, con $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ derivable, $\mathbf{W} \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$. Prueba que $\frac{\partial y}{\partial \mathbf{W}} = \mathbf{x} (\mathbf{u}^t \odot \boldsymbol{\varphi}'(\mathbf{h}))$ donde $\odot$ denota el producto Hadamard (elemental).

Solución:

$$\frac{\partial y}{\partial \mathbf{W}} = \mathbf{u}^t \frac{\partial \boldsymbol{\varphi}(\mathbf{h})}{\partial \mathbf{h}} \frac{\partial \mathbf{h}}{\partial \mathbf{W}} = (\mathbf{u}^t \odot \boldsymbol{\varphi}'(\mathbf{h})) \frac{\partial \mathbf{h}}{\partial \mathbf{W}} = \mathbf{x} (\mathbf{u}^t \odot \boldsymbol{\varphi}'(\mathbf{h}))$$

7 Optimización con restricciones

Problema: Halla un mínimo de $\mathcal{L}(\boldsymbol{\theta}) = \theta_1^2 + \theta_2^2$ sujeta a $h(\boldsymbol{\theta}) = 1 - \theta_1 - \theta_2 = 0$.

Solución: $L(\theta_1, \theta_2, \lambda) = \theta_1^2 + \theta_2^2 + \lambda(\theta_1 + \theta_2 - 1)$

$$\frac{\partial L}{\partial(\theta_1, \theta_2, \lambda)} = \begin{pmatrix} 2\theta_1 + \lambda \\ 2\theta_2 + \lambda \\ \theta_1 + \theta_2 - 1 \end{pmatrix} \Big|_{(\theta_1^*, \theta_2^*, \lambda^*)} = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \rightarrow \theta_1^* = \theta_2^* = 0.5$$

8 Distribución de Bernoulli

Problema. Halla la derivada de la sigmoide, $\sigma(x) = \frac{1}{1 + e^{-x}}$

Solución.

$$\begin{aligned}\frac{d\sigma(x)}{dx} &= -\frac{1}{(1 + e^{-x})^2} e^{-x}(-1) = \frac{e^{-x}}{(1 + e^{-x})^2} \\ &= \frac{1 + e^{-x} - 1}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} - \frac{1}{(1 + e^{-x})^2} = \frac{1}{1 + e^{-x}} \left(1 - \frac{1}{1 + e^{-x}}\right) \\ &= \sigma(x)(1 - \sigma(x)) = \sigma(x)\sigma(-x)\end{aligned}$$

Problema. Halla la derivada de $\sigma(\beta x) = \frac{1}{1 + e^{-\beta x}}$, donde β es una constante no negativa

Solución.

$$\frac{d\sigma(\beta x)}{dx} = \beta \sigma(\beta x) \sigma(-\beta x)$$

Problema. Halla la derivada de $\text{swish}(x) = x \sigma(\beta x) = \frac{x}{1 + e^{-\beta x}}$, donde β es una constante no negativa

Solución.

$$\begin{aligned}\frac{d \text{swish}(x)}{dx} &= \sigma(\beta x) + x \beta \sigma(\beta x)(1 - \sigma(\beta x)) \\ &= \beta x \sigma(\beta x) + \sigma(\beta x)(1 - \beta x \sigma(\beta x)) \\ &= \beta \text{swish}(x) + \sigma(\beta x)(1 - \beta \text{swish}(x))\end{aligned}$$

Problema. Halla la derivada de la tangente hiperbólica a partir de su definición en términos de la sigmoide:

$$\tanh(x) = 2\sigma(2x) - 1$$

Solución.

$$\begin{aligned}\frac{d \tanh(x)}{dx} &= 2 \frac{d\sigma(2x)}{dx} = 2\sigma(2x)\sigma(-2x)2 \\ &= 4\sigma(2x)(1 - \sigma(2x)) = 4\sigma(2x) - 4\sigma(2x)^2 \\ &= 1 - (4\sigma(2x)^2 - 4\sigma(2x) + 1) = 1 - (2\sigma(2x) - 1)^2 = 1 - \tanh(x)^2\end{aligned}$$

Problema. Halla la derivada de la tangente hiperbólica a partir de su definición usual:

$$\tanh(x) = \frac{\sinh(x)}{\cosh(x)} \quad \text{donde} \quad \sinh(x) = \frac{e^x - e^{-x}}{2} \quad \text{y} \quad \cosh(x) = \frac{e^x + e^{-x}}{2}$$

Solución.

$$\begin{aligned} \frac{d \tanh(x)}{dx} &= \sinh(x) \frac{d \cosh(x)^{-1}}{dx} + \cosh(x)^{-1} \frac{d \sinh(x)}{dx} \\ &= -\sinh(x) \frac{\sinh(x)}{\cosh(x)^2} + \cosh(x)^{-1} \cosh(x) = 1 - \tanh(x)^2 \end{aligned}$$

9 Distribución categórica

Problema. Halla la Jacobiana de la softmax con respecto a un vector de C logits

$$\frac{\partial \boldsymbol{\mu}}{\partial \mathbf{a}} = \begin{bmatrix} \frac{\partial \mu_1}{\partial \mathbf{a}} \\ \frac{\partial \mu_2}{\partial \mathbf{a}} \\ \vdots \\ \frac{\partial \mu_C}{\partial \mathbf{a}} \end{bmatrix} = \begin{bmatrix} \frac{\partial \mu_1}{\partial a_1} & \frac{\partial \mu_1}{\partial a_2} & \cdots & \frac{\partial \mu_1}{\partial a_C} \\ \frac{\partial \mu_2}{\partial a_1} & \frac{\partial \mu_2}{\partial a_2} & \cdots & \frac{\partial \mu_2}{\partial a_C} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \mu_C}{\partial a_1} & \frac{\partial \mu_C}{\partial a_2} & \cdots & \frac{\partial \mu_C}{\partial a_C} \end{bmatrix} \quad \text{donde} \quad \boldsymbol{\mu} = \mathcal{S}(\mathbf{a}) = \left(\frac{e^{a_1}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}}, \dots, \frac{e^{a_C}}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}} \right)^t$$

Solución.

$$\begin{aligned} \frac{\partial \mu_i}{\partial a_j} &= e^{a_i} \frac{\partial (\sum_{\tilde{c}} e^{a_{\tilde{c}}})^{-1}}{\partial a_j} + \frac{1}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}} \frac{\partial e^{a_i}}{\partial a_j} \\ &= -\frac{e^{a_i} e^{a_j}}{(\sum_{\tilde{c}} e^{a_{\tilde{c}}})^2} + \frac{e^{a_i} \mathbb{I}(i=j)}{\sum_{\tilde{c}} e^{a_{\tilde{c}}}} \\ &= \mu_i (\mathbb{I}(i=j) - \mu_j) \end{aligned}$$

$$\frac{\partial \boldsymbol{\mu}}{\partial \mathbf{a}} = \begin{bmatrix} \mu_1(1-\mu_1) & -\mu_1\mu_2 & \cdots & -\mu_1\mu_C \\ -\mu_2\mu_1 & \mu_2(1-\mu_2) & \cdots & -\mu_2\mu_C \\ \vdots & \vdots & \ddots & \vdots \\ -\mu_C\mu_1 & -\mu_C\mu_2 & \cdots & \mu_C(1-\mu_C) \end{bmatrix} = \text{diag}(\boldsymbol{\mu}) - \boldsymbol{\mu}\boldsymbol{\mu}^t$$

10 Distribución Gaussiana

☐ Dadas $\mu \in \mathbb{R}^D$ y $\Sigma \in \mathbb{R}^{D \times D}$, $\Sigma \succeq 0$, la densidad Gaussiana D -dimensional puede expresarse en términos de la distancia de Mahalanobis a μ (con respecto a Σ^{-1}) como sigue:

$$p(y) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} \Delta^2(y) \right] \quad \text{con} \quad \Delta(y) = \sqrt{(y - \mu)^t \Sigma^{-1} (y - \mu)}$$

Indica la respuesta incorrecta o la última opción si las tres primeras son correctas.

1. La densidad Gaussiana alcanza su máximo cuando $\Delta(y)$ es cero, esto es, en $y = \mu$.
2. Si Σ es la matriz identidad, la distancia de Mahalanobis a μ coincide con la distancia Euclídea al cuadrado.
3. Si Σ es distinta de la matriz identidad, los conjuntos de nivel de la Gaussiana son proporcionales a los de la distancia de Mahalanobis a μ y tienen forma de elipse centrada en μ .
4. Las tres opciones anteriores son correctas.

Solución: La 2; si Σ es la matriz identidad, la distancia de Mahalanobis a μ coincide con la distancia Euclídea **sin elevar al cuadrado**.

☐ La función de densidad de la Gaussiana D -dimensional es de la forma

$$p(y | \mu, \Sigma) = \frac{1}{(2\pi)^{D/2} \det \Sigma^{1/2}} \exp \left[-\frac{1}{2} (y - \mu)^t \Sigma^{-1} (y - \mu) \right], \quad \mu \in \mathbb{R}^D, \Sigma \in \mathbb{R}^{D \times D}, \Sigma \succeq 0$$

Sus conjuntos de nivel son proporcionales a los de la distancia de Mahalanobis entre y y μ . La forma de estos conjuntos, esto es, de la bola Gaussiana centrada en μ , depende de Σ . Suponiendo que $D = 2$, indica la respuesta incorrecta (o la última opción si las tres primeras son correctas).

1. Si $\Sigma = \sigma^2 \mathbf{I}$, la Gaussiana es circular.
2. Si Σ es diagonal, la Gaussiana es rectangular.
3. Si Σ no es diagonal (con elementos no nulos fuera de la diagonal), la Gaussiana es elíptica.
4. Las tres opciones anteriores son correctas.

Solución: La 2; si Σ es diagonal, la Gaussiana es elíptica, de semiejes alineados con los canónicos.

11 Entropía

☐ La entropía de una variable aleatoria discreta X con distribución p sobre K estados es:

$$\mathbb{H}(X) = - \sum_k p(X = k) \log_2 p(X = k) = -\mathbb{E}_X[\log p(X)]$$

La distribución de máxima entropía de X es:

1. Cualquier función delta que asigne toda la masa a un estado k^* , $p(X = k) = \delta(X = k^*)$
2. Cualquier función que asigne masa nula a al menos un estado k^* , $p(X = k^*) = 0$
3. La distribución uniforme, $p(X = k) = \frac{1}{K}$
4. Ninguna de las anteriores

Solución: La 3.

12 Estimación máximo-verosímil (MLE)

□ Sea $\mathcal{D} = \{(\mathbf{x}_n, \mathbf{y}_n)\}_{n=1}^N$ un conjunto de datos y sea $p(\mathcal{D} | \boldsymbol{\theta})$ la verosimilitud de un modelo gobernado por un vector de parámetros $\boldsymbol{\theta}$. Supón que la verosimilitud puede factorizarse de manera naïve como $p(\mathcal{D} | \boldsymbol{\theta}) = \prod_n p(\mathbf{y}_n | \mathbf{x}_n, \boldsymbol{\theta})$. Con base en esta asunción, se quiere hallar un estimador máximo-verosímil de $\boldsymbol{\theta}$, $\hat{\boldsymbol{\theta}}_{\text{mle}}$. Indica la respuesta incorrecta (o la última opción si las tres primeras son correctas).

1. $\hat{\boldsymbol{\theta}}_{\text{mle}} = \underset{\boldsymbol{\theta}}{\text{argmin}} - \sum_n \log p(\mathbf{y}_n | \mathbf{x}_n, \boldsymbol{\theta})$
2. $\hat{\boldsymbol{\theta}}_{\text{mle}} = \underset{\boldsymbol{\theta}}{\text{argmin}} - \sum_n \log p(\mathbf{x}_n, \mathbf{y}_n | \boldsymbol{\theta}) - \log p(\mathbf{x}_n | \boldsymbol{\theta})$
3. $\hat{\boldsymbol{\theta}}_{\text{mle}} = \underset{\boldsymbol{\theta}}{\text{argmin}} - \sum_n \log p(\mathbf{x}_n, \mathbf{y}_n | \boldsymbol{\theta})$
4. Las tres opciones anteriores son correctas.

Solución: La 3.

Problema. Sea $\mathcal{D} = \{\mathbf{y}_1, \dots, \mathbf{y}_N\}$ un conjunto de datos de una Gaussiana $p(\mathbf{y}_n | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \mathcal{N}(\mathbf{y}_n | \boldsymbol{\mu}, \boldsymbol{\Sigma})$. Prueba que el MLE de $\boldsymbol{\theta}$ es la media y matriz de covarianzas empíricas. Consulta [Matrix calculus en wikipedia](#), secciones [Scalar-by-vector identities](#) y [Scalar-by-matrix identities](#) (en formato numerador).

Solución.

$$\text{NLL}(\boldsymbol{\theta}) = -\frac{ND}{2} \log(2\pi) + \frac{N}{2} \log |\boldsymbol{\Sigma}| + \frac{1}{2} \sum_n (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{y}_n - \boldsymbol{\mu})$$

$$\begin{aligned} \frac{\partial \text{NLL}}{\partial \boldsymbol{\mu}} &= \frac{1}{2} \sum_n \frac{\partial (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{y}_n - \boldsymbol{\mu})}{\partial \boldsymbol{\mu}} \\ &= \frac{1}{2} \sum_n (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} \frac{\partial (\mathbf{y}_n - \boldsymbol{\mu})}{\partial \boldsymbol{\mu}} + (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-t} \frac{\partial (\mathbf{y}_n - \boldsymbol{\mu})}{\partial \boldsymbol{\mu}} \quad \left(\frac{\partial \mathbf{u}^t \mathbf{A} \mathbf{v}}{\partial \mathbf{x}} = \mathbf{u}^t \mathbf{A} \frac{\partial \mathbf{v}}{\partial \mathbf{x}} + \mathbf{v}^t \mathbf{A}^t \frac{\partial \mathbf{u}}{\partial \mathbf{x}} \right) \\ &= \frac{1}{2} \sum_n (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (-\mathbf{I}_D) + (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-t} (-\mathbf{I}_D) \\ &= \frac{1}{2} \sum_n -2(\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} = -\left(\sum_n (\mathbf{y}_n - \boldsymbol{\mu})^t \right) \boldsymbol{\Sigma}^{-1} \Big|_{\hat{\boldsymbol{\theta}}} = \mathbf{0}^t \rightarrow \hat{\boldsymbol{\mu}} = \bar{\mathbf{y}} \end{aligned}$$

$$\begin{aligned} \frac{\partial \text{NLL}}{\partial \boldsymbol{\Sigma}} &= \frac{N}{2} \boldsymbol{\Sigma}^{-1} + \frac{1}{2} \sum_n \frac{\partial (\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{y}_n - \boldsymbol{\mu})}{\partial \boldsymbol{\Sigma}} \quad \left(\frac{\partial \log |a\mathbf{X}|}{\partial \mathbf{X}} = \mathbf{X}^{-1} \right) \\ &= \frac{N}{2} \boldsymbol{\Sigma}^{-1} + \frac{1}{2} \sum_n \frac{\partial \text{tr}(\boldsymbol{\Sigma}^{-1} (\mathbf{y}_n - \boldsymbol{\mu})(\mathbf{y}_n - \boldsymbol{\mu})^t)}{\partial \boldsymbol{\Sigma}} \\ &= \frac{N}{2} \boldsymbol{\Sigma}^{-1} + \frac{1}{2} \sum_n -\boldsymbol{\Sigma}^{-1} (\mathbf{y}_n - \boldsymbol{\mu})(\mathbf{y}_n - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} \Big|_{\hat{\boldsymbol{\theta}}} = \mathbf{0} \quad \left(\frac{\partial \text{tr}(\mathbf{X}^{-1} \mathbf{A})}{\partial \mathbf{X}} = -\mathbf{X}^{-1} \mathbf{A} \mathbf{X}^{-1} \right) \\ &\rightarrow N \hat{\boldsymbol{\Sigma}}^{-1} = \hat{\boldsymbol{\Sigma}}^{-1} \sum_n (\mathbf{y}_n - \hat{\boldsymbol{\mu}})(\mathbf{y}_n - \hat{\boldsymbol{\mu}})^t \hat{\boldsymbol{\Sigma}}^{-1} \\ &\rightarrow \hat{\boldsymbol{\Sigma}} = \frac{1}{N} \sum_n (\mathbf{y}_n - \hat{\boldsymbol{\mu}})(\mathbf{y}_n - \hat{\boldsymbol{\mu}})^t \end{aligned}$$

13 Minimización del riesgo empírico (ERM)

Problema. Sea un problema de clasificación en dos clases, $y \in \{0, 1\}$, para el que se tiene un modelo Bernoulli condicional:

$$p(y | \mathbf{x}, \boldsymbol{\theta}) = \text{Ber}(y | \mu) \quad \text{con} \quad \hat{y} = \mu = \sigma(a), \quad a = f(\mathbf{x}, \boldsymbol{\theta})$$

Halla la derivada de la entropía cruzada binaria (con un dato) respecto de la logodds a ,

$$\frac{d\ell(y, \hat{y})}{da} \quad \text{con} \quad \ell(y, \hat{y}) = -y \log \hat{y} - (1 - y) \log(1 - \hat{y})$$

Solución.

$$\frac{d\ell(y, \hat{y})}{d\mu} = \frac{d\ell(y, \hat{y})}{d\hat{y}} \frac{d\hat{y}}{da} = \frac{\hat{y} - y}{\hat{y}(1 - \hat{y})} \hat{y}(1 - \hat{y}) = \hat{y} - y$$

Problema. Sea un problema de clasificación en C clases, $\mathbf{y} \in \{0, 1\}^C$, $\sum_c y_c = 1$, para el que se tiene un modelo categórico condicional:

$$p(\mathbf{y} | \mathbf{x}, \boldsymbol{\theta}) = \text{Cat}(\mathbf{y} | \boldsymbol{\mu}) \quad \text{con} \quad \hat{\mathbf{y}} = \boldsymbol{\mu} = \mathcal{S}(\mathbf{a}), \quad \mathbf{a} = f(\mathbf{x}, \boldsymbol{\theta})$$

Halla la derivada de la entropía cruzada (con un dato) respecto del vector de logits $\mathbf{a}$,

$$\frac{\partial \ell(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{a}} \quad \text{con} \quad \ell(\mathbf{y}, \hat{\mathbf{y}}) = -\sum_c y_c \log \hat{y}_c$$

Solución.

$$\begin{aligned} \frac{\partial \ell(\mathbf{y}, \hat{\mathbf{y}})}{\partial \mathbf{a}} &= \frac{\partial \ell(\mathbf{y}, \hat{\mathbf{y}})}{\partial \hat{\mathbf{y}}} \frac{\partial \hat{\mathbf{y}}}{\partial \mathbf{a}} \\ &= -(\mathbf{y}^t \oslash \hat{\mathbf{y}}^t)(\text{diag}(\boldsymbol{\mu}) - \boldsymbol{\mu} \boldsymbol{\mu}^t) \\ &= (\mathbf{y}^t \oslash \boldsymbol{\mu}^t) \boldsymbol{\mu} \boldsymbol{\mu}^t - (\mathbf{y}^t \oslash \boldsymbol{\mu}^t) \text{diag}(\boldsymbol{\mu}) \\ &= \begin{bmatrix} \frac{y_1}{\mu_1}, \dots, \frac{y_C}{\mu_C} \end{bmatrix} \begin{bmatrix} \mu_1^2 & \mu_1 \mu_2 & \dots & \mu_1 \mu_C \\ \mu_2 \mu_1 & \mu_2^2 & \dots & \mu_2 \mu_C \\ \vdots & \vdots & \ddots & \vdots \\ \mu_C \mu_1 & \mu_C \mu_2 & \dots & \mu_C^2 \end{bmatrix} - \begin{bmatrix} \frac{y_1}{\mu_1}, \dots, \frac{y_C}{\mu_C} \end{bmatrix} \begin{bmatrix} \mu_1 & 0 & \dots & 0 \\ 0 & \mu_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \mu_C \end{bmatrix} \\ &= (\boldsymbol{\mu} - \mathbf{y})^t = (\hat{\mathbf{y}} - \mathbf{y})^t \end{aligned}$$

14 Regularización

☐ Uno de los grandes retos del aprendizaje automático consiste en aprender modelos que generalicen bien, esto es, que no se limiten a predecir correctamente los datos de entrenamiento, sino que también predigan bien datos futuros. Con el fin de afrontar este reto, se suelen seguir varias estrategias convencionales que por lo general dan buen resultado. Indica cuál de las siguientes estrategias **no** es una estrategia convencional para generalizar mejor (o escoge la última opción si las tres primeras sí lo son).

1. Regularización.
2. Terminación temprana (asumiendo que se usa un algoritmo de aprendizaje iterativo).
3. Uso de más datos.
4. Las tres opciones anteriores son estrategias convencionales para generalizar mejor.

Solución: La 4.

15 Decisión

□ En un problema de clasificación en C clases, tanto los posibles estados de la naturaleza como las posibles acciones son etiquetas de clase, $\mathcal{H} = \mathcal{A} = \mathcal{Y} = \{1, \dots, C\}$. Supón que la pérdida asociada a cada par estado-acción es la 0-1, $\ell(y^*, \hat{y}) = \mathbb{I}(y^* \neq \hat{y})$, donde y^* denota la clase verdadera y $\hat{y}$ la predicha. Dada una observación $\mathbf{x}$, el riesgo de una acción $\hat{y}$ y la acción de mínimo riesgo (regla de Bayes) son:

1. $R(\hat{y} | \mathbf{x}) = 1 - p(y^* = \hat{y} | \mathbf{x})$ y $\pi^*(\mathbf{x}) = \operatorname{argmin}_{y \in \mathcal{Y}} p(y | \mathbf{x})$
2. $R(\hat{y} | \mathbf{x}) = 1 - p(y^* = \hat{y} | \mathbf{x})$ y $\pi^*(\mathbf{x}) = \operatorname{argmax}_{y \in \mathcal{Y}} p(y | \mathbf{x})$
3. $R(\hat{y} | \mathbf{x}) = 1 - p(y^* \neq \hat{y} | \mathbf{x})$ y $\pi^*(\mathbf{x}) = \operatorname{argmin}_{y \in \mathcal{Y}} p(y | \mathbf{x})$
4. $R(\hat{y} | \mathbf{x}) = 1 - p(y^* \neq \hat{y} | \mathbf{x})$ y $\pi^*(\mathbf{x}) = \operatorname{argmax}_{y \in \mathcal{Y}} p(y | \mathbf{x})$

Solución: La 2.

□ En un problema de clasificación en C clases, tanto los posibles estados de la naturaleza como las posibles acciones son etiquetas de clase, $\mathcal{H} = \mathcal{A} = \mathcal{Y} = \{1, \dots, C\}$. Si la pérdida asociada a cada par estado-acción es la 0-1, $\ell(y^*, \hat{y}) = \mathbb{I}(y^* \neq \hat{y})$, la pérdida esperada de una acción $\hat{y}$, a posteriori de una observación $\mathbf{x}$, es:

1. $R(\hat{y} | \mathbf{x}) = p(y = \hat{y} | \mathbf{x})$
2. $R(\hat{y} | \mathbf{x}) = 1 - p(y = \hat{y} | \mathbf{x})$
3. $R(\hat{y} | \mathbf{x}) = 1 - p(y \neq \hat{y} | \mathbf{x})$
4. Ninguna de las anteriores

Solución: La 2.
