

CLASIFICACIÓN DE TEXTOS

Lingüística Computacional



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Máster en Inteligencia Artificial,
Reconocimiento de Formas
e Imagen Digital

DSIC

CLASIFICACIÓN DE TEXTOS

- **Introducción a la clasificación de textos**
- **Naïve Bayes**
- **Regresión Logística**

CLASIFICACIÓN DE TEXTOS

- **Introducción a la clasificación de textos**
- **Naïve Bayes**
- **Regresión Logística**

CLASIFICACIÓN DE TEXTOS

La clasificación de textos tiene un papel central en la Lingüística Computacional, ya que permite convertir lenguaje natural no estructurado en datos organizados y significativos, extraer conocimiento del texto. Esta tarea automatiza la asignación de etiquetas o categorías a documentos, facilitando así el análisis, la búsqueda y la comprensión del lenguaje por parte de las máquinas. Constituye la base de numerosas aplicaciones prácticas en el procesamiento del lenguaje natural, desde asistentes virtuales hasta sistemas de recomendación.

CLASIFICACIÓN DE TEXTOS

Algunos ejemplos de aplicación de la clasificación de textos:

- Detección de spam: clasificar correos electrónicos como "spam" o "no spam".
- Análisis de sentimientos: determinar si una reseña o comentario es positivo, negativo o neutro.
- Categorización de noticias: asignar artículos a categorías temáticas como "deportes", "política", "economía" o "tecnología".
- Identificación de idioma: reconocer automáticamente el idioma en el que está escrito un texto.
- Clasificación de intención en chatbots: identificar la intención del usuario ("solicitar soporte", "hacer una reserva", "consultar precios", ...) para responder adecuadamente.

CLASIFICACIÓN DE TEXTOS

Ejemplos, detección de spam

Estimado Señor:

Por favor, encuentre adjuntos los formularios que solicitó.

Nota especial: El estudiante debe presentar los formularios firmados a mano el primer día de inscripción. (Formularios adjuntos)

NOTA IMPORTANTE: Será necesario proporcionar extractos bancarios adicionales y documentación de respaldo si el estudiante ha completado estudios fuera de su país de origen. (Documentos válidos: recibo de electricidad, contrato de arrendamiento, extracto bancario, carné de la universidad).

No dude en contactarnos si tiene alguna pregunta.

Study Abroad Partners

CLASIFICACIÓN DE TEXTOS

Ejemplos, análisis de sentimientos (polaridad)



- Increíblemente decepcionante



- Llena de personajes excéntricos y sátira bien lograda, además de giros argumentales excelentes



- Esta es la mejor comedia de enredo jamás filmada



- Fue patética. Lo peor de todo fueron las escenas de boxeo

CLASIFICACIÓN DE TEXTOS

Formalización

- *Entrada:*
 - un documento d
 - un conjunto fijo de clases $Y = \{y_1, y_2, \dots, y_{|Y|}\}$
- *Salida:* una clase $\hat{y} \in Y$, asignada por el modelo al documento d .

CLASIFICACIÓN SUPERVISADA DE TEXTOS

Formalización

• Entrenamiento

Entrada:

- un conjunto fijo de clases $Y = \{y_1, y_2, \dots, y_{|Y|}\}$
- un conjunto de entrenamiento $m = \{(x^1, y^1), \dots, (x^m, y^m)\}$,
donde x^i es un documento y $y^i \in Y$ es la clase asignada a
mano por un etiquetador al documento x^i

Salida:

- un clasificador $\gamma: d \rightarrow \hat{y}$

• Inferencia/Test

Entrada: un documento d

Salida: una clase $\hat{y} \in Y$

CLASIFICACIÓN SUPERVISADA DE TEXTOS

Ejemplos de clasificadores

Algunos clasificadores utilizados para Clasificación de textos:

- Naive Bayes
- Regresión Logística
- Redes Neurales
- Máquinas de Vectores de Soporte (SVM)
- k -vecinos más próximos
- Large Language Model (LLM)
 - Fine-tuning
 - Prompting

CLASIFICACIÓN DE TEXTOS

- Introducción a la clasificación de textos
- **Naïve Bayes**
- Regresión Logística

Naïve Bayes para Clasificación de Textos

Clasificador muy simple basado en la regla de Bayes.

Representa los documentos como **bolsas de palabras**.

I love this movie! It's sweet,
but with satirical humor. The
dialogue is great and the
adventure scenes are fun...
It manages to be whimsical
and romantic while laughing
at the conventions of the
fairy tale genre. I would
recommend it to just about
anyone. I've seen it several
times, and I'm always happy
to see it again whenever I
have a friend who hasn't
seen it yet!



it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1
...	...

Naïve Bayes para Clasificación de Textos

$$Y(\text{table}) = C$$

seen	2
sweet	1
whimsical	1
recommend	1
happy	1
...	...

Naïve Bayes para Clasificación de Textos

Regla de Bayes

- Para un documento d y una clase c

$$P(c | d) = \frac{P(d | c)P(c)}{P(d)}$$

Naïve Bayes para Clasificación de Textos

$$\begin{aligned}c_{MAP} &= \operatorname{argmax}_{c \in C} P(c \mid d) \\&= \operatorname{argmax}_{c \in C} \frac{P(d \mid c)P(c)}{P(d)} \\&= \operatorname{argmax}_{c \in C} P(d \mid c)P(c)\end{aligned}$$

Naïve Bayes para Clasificación de Textos

Verosimilitud

Probabilidad
a Priori

$$c_{MAP} = \operatorname{argmax}_{c \in C} P(d \mid c)P(c)$$

$$= \operatorname{argmax}_{c \in C} \underbrace{P(x_1, x_2, \dots, x_n \mid c)}_{\text{Features del documento}} P(c)$$

Features del documento

Naïve Bayes para Clasificación de Textos

Asunción de independencia

$$P(x_1, x_2, \dots, x_n \mid c)$$

- **Bag of Words:** La posición de las palabras no importan
- **Independencia condicional:** Las características $P(x_i \mid c_j)$ son independientes para la clase c .

$$P(x_1, \dots, x_n \mid c) = P(x_1 \mid c) \square P(x_2 \mid c) \square P(x_3 \mid c) \square \dots \square P(x_n \mid c)$$

Naïve Bayes para Clasificación de Textos

$$c_{MAP} = \operatorname{argmax}_{c \in C} P(x_1, x_2, \dots, x_n | c) P(c)$$

$$c_{NB} = \operatorname{argmax}_{c \in C} P(c_j) \prod_{x \in X} P(x | c)$$

$$c_{NB} = \operatorname{argmax}_{c_j \in C} P(c_j) \prod_{i \in \text{positions}} P(x_i | c_j)$$

Los tokens del documento de test

Naïve Bayes para Clasificación de Textos

Underflow

Problema:

- Las probabilidades son números muy pequeños representados en coma flotante.
- Multiplicar muchos números muy pequeños en coma flotante puede producir un subdesbordamiento (**underflow**).

Solución:

- Utilizar el logaritmo de las probabilidades (log probabilidades) en lugar de las probabilidades.

Naïve Bayes para Clasificación de Textos

Underflow

En lugar de calcular:

$$c_{NB} = \operatorname{argmax}_{c_j \in C} \prod_{i \in \text{positions}} P(x_i | c_j)$$

Calculamos:

$$c_{NB} = \operatorname{argmax}_{c_j \in C} \left[\log P(c_j) + \sum_{i \in \text{positions}} \log P(x_i | c_j) \right]$$

Nota:

Utilizar logaritmos no cambia el resultado del *argmax*.

Se trata de un **modelo lineal**: maximización de la suma de pesos.

Naïve Bayes para Clasificación de Textos

Entrenamiento

Estimación por máxima verosimilitud

$$\hat{P}(c_j) = \frac{N_{c_j}}{N_{total}}$$

Porcentaje de documentos que son de la clase c_j

$$\hat{P}(w_i | c_j) = \frac{\text{count}(w_i, c_j)}{\sum_{w \in V} \text{count}(w, c_j)}$$

Frecuencia de la palabra w_i en los documentos de la clase c_j

Naïve Bayes para Clasificación de Textos

Entrenamiento

Estimación por máxima verosimilitud

$$\hat{P}(w_i | c_j) = \frac{\text{count}(w_i, c_j)}{\sum_{w \in V} \text{count}(w, c_j)}$$

Frecuencia de la palabra w_i en el megadocumento de la clase c_j

Nota: Dado que las posiciones de las palabras no importan (asunción de independencia condicional), se puede hacer un único megadocumento para cada clase uniendo todos sus documentos.

Naïve Bayes para Clasificación de Textos

Entrenamiento, cobertura

¿Qué ocurre si la palabra ***fantastic*** no aparece en ningún documento de la clase ***positivo*** pero sí en otras clases?

$$\hat{P}(\text{"fantastic"} \mid \text{positive}) = \frac{\text{count}(\text{"fantastic"}, \text{positive})}{\sum_{w \in V} \text{count}(w, \text{positive})} = 0$$

Cualquier palabra que forme parte del vocabulario del clasificador, pero no se ha visto en entrenamiento en la clase ***c*** hace que la probabilidad del documento para esa clase sea cero.

$$c_{MAP} = \operatorname{argmax}_c \hat{P}(c) \prod_i \hat{P}(x_i \mid c)$$

¿Solución?

Naïve Bayes para Clasificación de Textos

Entrenamiento, suavizado Laplace (suma α)

$$\hat{P}(w_i|c) = \frac{\text{count}(w_i, c)}{\sum_{w \in V} \text{count}(w, c)} \approx$$

$$\hat{P}(w_i|c) = \frac{\text{count}(w_i, c) + \alpha}{\sum_{w \in V} (\text{count}(w, c) + \alpha)}$$

$$\hat{P}(w_i|c) = \frac{\text{count}(w_i, c) + \alpha}{\sum_{w \in V} (\text{count}(w, c)) + |V|\alpha}$$

Naïve Bayes para Clasificación de Textos

Entrenamiento, algoritmo

1. Extraer el vocabulario de todo el corpus de entrenamiento

2. Calcular $P(c_j)$:

Para cada clase c_j :

$$P(c_j) = \frac{\# \text{ docs clase } c_j}{\# \text{ total de documentos}}$$

3. Calcular $P(w_k | c_j)$:

Para cada clase c_j :

$Text_j$ = concatenación de los documentos de la clase c_j

$n = |Text_j|$

Para cada palabra w_k del vocabulario:

n_k = número de ocurrencias de w_k en $Text_j$

$$P(w_k | c_j) = \frac{n_k + \alpha}{n + |Vocabulario|\alpha}$$

Naïve Bayes para Clasificación de Textos

Entrenamiento, palabra desconocida

¿Qué hacemos con las palabras desconocidas (OOV)?

- Son palabras que aparecen en los datos de test
- pero no en los documentos de entrenamiento

A diferencia de en los modelos de lenguaje, aquí las OOV se **ignoran**:

- Se eliminan de los documentos de test y
- No se les asigna probabilidad.

¿Por qué no se hace un modelo para las OOV?

- Solo sirve para dar ventaja a las clases que tienen más OOV, no parece muy útil.

Naïve Bayes para Clasificación de Textos

Entrenamiento, stop words (palabras vacías)

- Palabras vacías: palabras muy frecuentes y sin significado como "el" y "un".
- Se pueden utilizar listas predeterminadas de stop words o utilizar las frecuencias de las palabras en el corpus de entrenamiento para descartar las más frecuentes (aproximadamente entre 20 y 150).
- Algunos sistemas ignoran las palabras vacías y las eliminan del corpus de entrenamiento. No importa eliminarlas del test.
- Pero eliminar palabras vacías generalmente no ayuda mucho.

```
import nltk  
nltk.download('stopwords')
```

```
from nltk.corpus import stopwords  
stop_words_en = stopwords.words('english')
```

Naïve Bayes para Clasificación de Textos

Ejemplo, análisis de sentimientos

	Cat	Documents
Training	-	just plain boring
	-	entirely predictable and lacks energy
	-	no surprises and very few laughs
	+	very powerful
	+	the most fun film of the summer
Test	?	predictable with no fun

Naïve Bayes para Clasificación de Textos

Ejemplo

	Cat	Documents
Training	-	just plain boring
	-	entirely predictable and lacks energy
	-	no surprises and very few laughs
	+	very powerful
	+	the most fun film of the summer
Test	?	predictable with no fun

1. Probabilidades a Priori:

$$\hat{P}(c_j) = \frac{N_{c_j}}{N_{total}} \quad \begin{array}{l} P(-) = 3/5 \\ P(+) = 2/5 \end{array}$$

2. Eliminamos 'with':

3. Verosimilitudes:

$$p(w_i|c) = \frac{\text{count}(w_i, c) + 1}{(\sum_{w \in V} \text{count}(w, c)) + |V|}$$

$$P(\text{"predictable"}|-) = \frac{1+1}{14+20} \quad P(\text{"predictable"}|+) = \frac{0+1}{9+20}$$

$$P(\text{"no"}|-) = \frac{1+1}{14+20} \quad P(\text{"no"}|+) = \frac{0+1}{9+20}$$

$$P(\text{"fun"}|-) = \frac{0+1}{14+20} \quad P(\text{"fun"}|+) = \frac{1+1}{9+20}$$

4. Probabilidad final:

$$P(-)P(S|-) = \frac{3}{5} \times \frac{2 \times 2 \times 1}{34^3} = 6.1 \times 10^{-5}$$

$$P(+)P(S|+) = \frac{2}{5} \times \frac{1 \times 1 \times 2}{29^3} = 3.2 \times 10^{-5}$$

CLASIFICACIÓN DE TEXTOS

- Introducción a la clasificación de textos
- Naïve Bayes
- Regresión Logística

Regresión Logística para Clasificación de Textos

- Herramienta analítica importante en ciencias naturales y sociales.
- Baseline de aprendizaje automático supervisado para clasificación.
- Es la base de las redes neuronales.

Regresión Logística para Clasificación de Textos

Componentes de un clasificador

Dados m pares entrada/salida $(x^{(i)}, y^{(i)})$:

1. Una **representación de características** de la entrada. Para cada observación de entrada $x^{(i)}$, un vector de características $[x_1, x_2, \dots, x_n]$. La característica j para la entrada $x^{(i)}$ es $x_j^{(i)}$.
2. Una **función de clasificación** que calcula la clase estimada, $\hat{y}$, mediante $p(y|x)$, como las funciones sigmoide o softmax.
3. Una función objetivo (función de pérdida/loss) para el aprendizaje, como la **entropía cruzada**.
4. Un algoritmo para optimizar la función objetivo: **descenso por gradiente**.

Regresión Logística para Clasificación de Textos

Dos Fases

- **Entrenamiento:** Aprendemos los pesos w y b usando **descenso por gradiente estocástico** y **la entropía cruzada** como función de pérdida.
- **Prueba/inferencia:** Dado un ejemplo de test o un ejemplo real x , calculamos $p(y|x)$ usando los pesos aprendidos w y b , y devolvemos la etiqueta que tenga mayor probabilidad.

•

Regresión Logística para Clasificación de Textos

Dcaracterísticas y pesos

Para la característica x_i el peso w_i indica cuán importante y en qué sentido es esa característica para la clasificación.

Ejemplo: un sistema de análisis de sentimientos sobre reseñas de películas.

x_1 = “la reseña contiene ‘fantástico’”: $w_1 = +10$

x_2 = “la reseña contiene ‘horrible’”: $w_2 = -10$

x_3 = “la reseña contiene ‘mediocre’”: $w_3 = -2$

Regresión Logística para Clasificación de Textos

¿Cómo se clasifica una muestra?

- Entrada: vector de características $x = [x_1, x_2, \dots, x_n]$
- Pesos: un peso por característica: $W = [w_1, w_2, \dots, w_n]$
 - También se suelen llamar $\theta = [\theta_1, \theta_2, \dots, \theta_n]$
- Salida: la clase predicha, $\hat{y}$

Regresión Logística para Clasificación de Textos

¿Cómo se clasifica una muestra?

Además de los pesos tenemos un sesgo (bias) **b** .

El resultado **z** es la suma de todas las características ponderadas por su peso más el bias.

$$z = \left(\sum_{i=1}^n x_i w_i \right) + b$$

Lo podemos representar como el producto escalar de dos vectores.

$$z = W \cdot X + b$$

En una clasificación binaria si la suma es alta $y=1$ y si es baja $y=0$

Regresión Logística para Clasificación de Textos

¿Cómo se clasifica una muestra?, clasificación binaria

$$z = W \cdot X + b$$

En una clasificación binaria si **z** es alta $y = 1$ y si es baja $y = 0$

Pero, ¿qué es un valor alto o un valor bajo?

Lo que se busca es un clasificador que asigne una probabilidad a cada clase:

$$0 \leq p(y = 1|x; \theta) \leq 1;$$

$$0 \leq p(y = 0|x; \theta) \leq 1;$$

y

$$p(y = 1|x; \theta) + p(y = 0|x; \theta) = 1$$

Regresión Logística para Clasificación de Textos

Clasificación binaria, z no es una probabilidad

Problema: tal como está definida, z no es una probabilidad.


$$z = W \cdot X + b$$

Solución: aplicar una función a z que vaya entre 0 y 1.

$$y = \sigma(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + \exp(-z)}$$

Regresión Logística para Clasificación de Textos

Clasificación binaria, la función sigmoide



Regresión Logística para Clasificación de Textos

¿Cómo se clasifica una muestra?, clasificación binaria

En resumen:

1. Calculamos $w \cdot x + b$
2. Le aplicamos la función sigmoide

$$\sigma(w \cdot x + b) = \frac{1}{1 + \exp(-(w \cdot x + b))}$$

3. El resultado es la probabilidad de que la muestra sea de la clase positiva, $y=1$

Regresión Logística para Clasificación de Textos

clasificación binaria, probabilidad de la clase negativa

Una característica de la función sigmoide es:

$$1 - \sigma(x) = \sigma(-x)$$

En consecuencia:

$$p(y = 1) = \sigma(w \cdot x + b)$$

$$p(y = 0) = 1 - p(y = 1) = 1 - \sigma(w \cdot x + b) = \sigma(-(w \cdot x + b))$$

$$p(y = 0) = \sigma(-(w \cdot x + b))$$

Regresión Logística para Clasificación de Textos

clasificación binaria, demostración $1 - \sigma(x) = \sigma(-x)$

$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$

$$\begin{aligned} 1 - \sigma(x) &= 1 - \frac{1}{1 + \exp(-x)} = \\ &\frac{1 + \exp(-x)}{1 + \exp(-x)} - \frac{1}{1 + \exp(-x)} \\ &= \frac{\exp(-x)}{1 + \exp(-x)} \end{aligned}$$

Regresión Logística para Clasificación de Textos

clasificación binaria, demostración $1 - \sigma(x) = \sigma(-x)$

$$1 - \sigma(x) = \frac{\exp(-x)}{1 + \exp(-x)}$$

$$\begin{aligned}\sigma(-x) &= \frac{1}{1 + \exp(x)} = \frac{\exp(-x)}{\exp(-x)} \cdot \frac{1}{1 + \exp(x)} = \\ &= \frac{\exp(-x)}{\exp(-x) + \exp(-x) \cdot \exp(x)} = \frac{\exp(-x)}{\exp(-x) + \exp(-x + x)} =\end{aligned}$$

$$\frac{\exp(-x)}{\exp(-x) + \exp(0)} = \frac{\exp(-x)}{\exp(-x) + 1} = \frac{\exp(-x)}{1 + \exp(-x)}$$

Regresión Logística para Clasificación de Textos

¿Cómo se clasifica una muestra?, clasificación binaria

Tenemos probabilidades, nos falta un paso para tener un clasificado


$$\hat{y} = \begin{cases} 1, & p(y = 1|x; \theta) \geq 0.5 \\ 0, & \text{en caso contrario} \end{cases}$$

0.5 es el límite de decisión (**decision boundary**)

Regresión Logística para Clasificación de Textos

Clasificación binaria, clasificador probabilístico

$p(y = 1)$



$$p(y = 1|x; \theta) = \sigma(w \cdot x + b) = \frac{1}{1 + e^{-(w \cdot x + b)}}$$

Regresión Logística para Clasificación de Textos

¿Cómo se clasifica una muestra?, clasificación binaria

Ya tenemos listo nuestro clasificador binario

$$\hat{y} = \begin{cases} 1, & p(y = 1|x; \theta) \geq 0.5, \text{ si } w \cdot x + b \geq 0 \\ 0, & \text{en caso contrario, si } w \cdot x + b < 0 \end{cases}$$

Regresión Logística para Clasificación de Textos


Clasificación binaria, un ejemplo (polaridad)

It's hokey . There are virtually no surprises , and the writing is second-rate .
So why was it so enjoyable ? For one thing , the cast is great . Another nice
touch is the music. I was overcome with the urge to get off the couch and start
dancing . It sucked me in , and it'll do the same to you .

*Es cursi. Virtualmente no hay sorpresas, y la escritura es de segunda
categoría. ¿Entonces por qué fue tan disfrutable? Por una cosa, el elenco
es genial. Otro toque agradable es la música. Me invadió el impulso de
levantarme del sofá y empezar a bailar. Me atrapó, y hará lo mismo contigo.*

Regresión Logística para Clasificación de Textos

Clasificación binaria, un ejemplo (polaridad)



Var	Definition	Value
x_1	count(positive lexicon) $\in$ doc)	3
x_2	count(negative lexicon) $\in$ doc)	2
x_3	$\begin{cases} 1 & \text{if "no" } \in \text{ doc} \\ 0 & \text{otherwise} \end{cases}$	1
x_4	count(1st and 2nd pronouns $\in$ doc)	3
x_5	$\begin{cases} 1 & \text{if "!" } \in \text{ doc} \\ 0 & \text{otherwise} \end{cases}$	0
x_6	log(word count of doc)	$\ln(66) = 4.19$

Regresión Logística para Clasificación de Textos

Clasificación binaria, un ejemplo (polaridad)

Var	Definition	Value
x_1	count(positive lexicon) $\in$ doc)	3
x_2	count(negative lexicon) $\in$ doc)	2
x_3	$\begin{cases} 1 & \text{if "no"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	1
x_4	count(1st and 2nd pronouns $\in$ doc)	3
x_5	$\begin{cases} 1 & \text{if "!"} \in \text{doc} \\ 0 & \text{otherwise} \end{cases}$	0
x_6	log(word count of doc)	$\ln(66) = 4.19$

Supongamos, $w = [2.5, -5.0, -1.2, 0.5, 2.0, 0.7]$

$$b = 0.1$$

Regresión Logística para Clasificación de Textos

Clasificación binaria, un ejemplo (polaridad)

$$\begin{aligned} p(+|x) &= P(Y = 1|x) = s(w \cdot x + b) \\ &= s([2.5, -5.0, -1.2, 0.5, 2.0, 0.7] \cdot [3, 2, 1, 3, 0, 4.19] + 0.1) \\ &= s(.833) \\ &= 0.70 \end{aligned}$$

$$\begin{aligned} p(-|x) &= P(Y = 0|x) = 1 - s(w \cdot x + b) \\ &= 0.30 \end{aligned}$$

Regresión Logística para Clasificación de Textos

Clasificación binaria, resumen

Dado:

- Un conjunto (binario) de clases: (+, -)
- Un vector **x** de características $[x_1, x_2, \dots, x_n]$
 - $x_1 = \text{count}(\text{palabras positivas})$
 - $x_2 = \log(\text{numero de palabras})$
- Un vector **w** de pesos $[w_1, w_2, \dots, w_n]$, un peso w_i por cada característica x_i
- Un bias **b**

Calculamos la probabilidad de la clase positiva como:

$$p(y = 1|x; w) = \sigma(w \cdot x + b) = \frac{1}{1 + e^{-(w \cdot x + b)}}$$